.UBAeconómicas |posgrado

1821 Universidad de Buenos Aires

ENAP Escuela de Negocios y Administración Pública

MAESTRÍA EN GESTIÓN Y ANÁLISIS DE DATOS

FUNDAMENTOS DE MÉTODOS ANALÍTICOS PREDICTIVOS

EVALUACIÓN FINAL

DOCENTES: RODRIGO DEL ROSSO-PATRICIA GIRIMONTE

ESTUDIANTE: LUIS ADAN CUENCA LAJMADI

2025

Predicción del Precio del Oro utilizando Métodos de Machine Learning

Problema a Resolver

Predecir la cotización del precio de cierre del oro del día siguiente a aquel en el que nos encontramos que pueda contribuir a mejorar la rentabilidad de una estrategia de trading. Se busco desarrollar modelos predictivos capaces de estimar el precio futuro de cierre del oro (*Close*) utilizando variables técnicas derivadas de series temporales históricas, como también variables utilizadas en el análisis técnico de los mercados. Se aplicarán tres enfoques: una red neuronal LSTM (no ensamblado), Gradient Boosting Regressor (GBR) y Random Forest (FR) (ensambles), comparando su rendimiento mediante métricas validadas.

Variables Utilizadas:

- **Variables Predictoras (features):**
    1. *ScaledReturn*: Retorno diario escalado (Close - Open).
    2. *ScaledVolatility*: Volatilidad diaria escalada (High - Low).
    3. *ScaledVolume*: Volumen de operaciones escalado.
    4. *Medias Moviles*.
    5. *Bandas de Bolinger*.
    6. *ADX*.
    7. *Lag (opr t*-20 periodos)
    8. *Close, High, Low, Open, Volume.*

- **Variable Objetivo (target):**
  Close: Precio de cierre del oro 'T+1' (para evaluación final) o *ScaledReturn* (para predicción de retornos).

Metodología:

1. **Preprocesamiento:**
    - Descargas de datos desde YF desde el año 2000.
    - Ajuste del DF y detección de datos faltantes.
    - Incorporación de Indicadores técnicos. Eliminando los Nan generados por la obtención de la ema.
    - Para LSTM, normalización exponencial (EWMA) para las variables.
    - Creación de ventanas temporales (*window_size=20*) para la LSTM.
2. **Modelos:**
    - **LSTM:** Red neuronal con capas recurrentes para capturar dependencias temporales.
    - **GBR y FR:** Ensambles basados en árboles, con actualización de datos previo cada predicción.
3. **Validación:**
    - **Métricas:** MSE y MAE en escala original (precios) y correlación Pearson.
    - **Validación Cruzada:** *TimeSeriesSplit* (5 folds) para todos los modelos.
    - **Selección de Parámetros:** RandomizedSearchCV para GBR y FR.

Resultados Esperados:

- Comparativa de desempeño: LSTM (patrones temporales) vs. ensambles (relaciones no lineales).

- Impacto económico: Rentabilidad positiva en al menos uno de los modelos.

Modelo RandomForestRegresor

El modelo de Random Forest se implementó utilizando un conjunto de variables técnicas clave, incluyendo precios históricos (Close, High, Low, Open), volumen e indicadores como ADX, EMA y Bandas de Bollinger. Estas features se eligieron para capturar patrones de mercado y tendencias, mientras que los lags temporales (Lag_1 a Lag_20) permitieron incorporar dependencias históricas. La decisión de mantener estas variables se basó en su relevancia para el análisis técnico y su capacidad para modelar relaciones no lineales, típicas en los mercados financieros.

Para mejor eficiencia, se redujo la dimensionalidad utilizando los últimos 1,260 datos, equilibrando actualidad y capacidad de procesamiento. El modelo se configuró con 100 árboles (n_estimators=100) y una semilla fija (random_state=42) para asegurar reproducibilidad. El test se realizó con una ventana móvil de 1,008 datos para entrenamiento y 252 para prueba, simulando un entorno real donde el modelo se actualiza diariamente con los datos y se efectúa una predicción para el día siguiente.

Las métricas mostraron un R^2 alto (0.9781), indicando un buen ajuste, aunque este resultado podría estar influenciado por la autocorrelación natural de los precios. El MAE de 31.65 sugiere errores absolutos moderados, cuya importancia depende del rango de precios del oro. En términos operativos, el modelo generó una rentabilidad del 27.83% con un 62% de operaciones positivas, lo que señala capacidad predictiva, pero sin descartar la necesidad de compararlo con estrategias más simples para validar su verdadero aporte.

Reflexiones Finales y Mejoras Potenciales

Si bien el modelo demostró ser útil, es importante considerar que su desempeño podría optimizarse incorporando variables macroeconómicas. Además, evaluar su rendimiento en períodos de alta volatilidad ayudaría a verificar su robustez, aunque esto en la actualidad no sea tan probable por el gran volumen de negociaciones necesarios para tener un impacto significativo en la variación de la cotización del oro. La autocorrelación sigue siendo un factor a monitorear, ya que puede incrementarr artificialmente las métricas de evaluación.

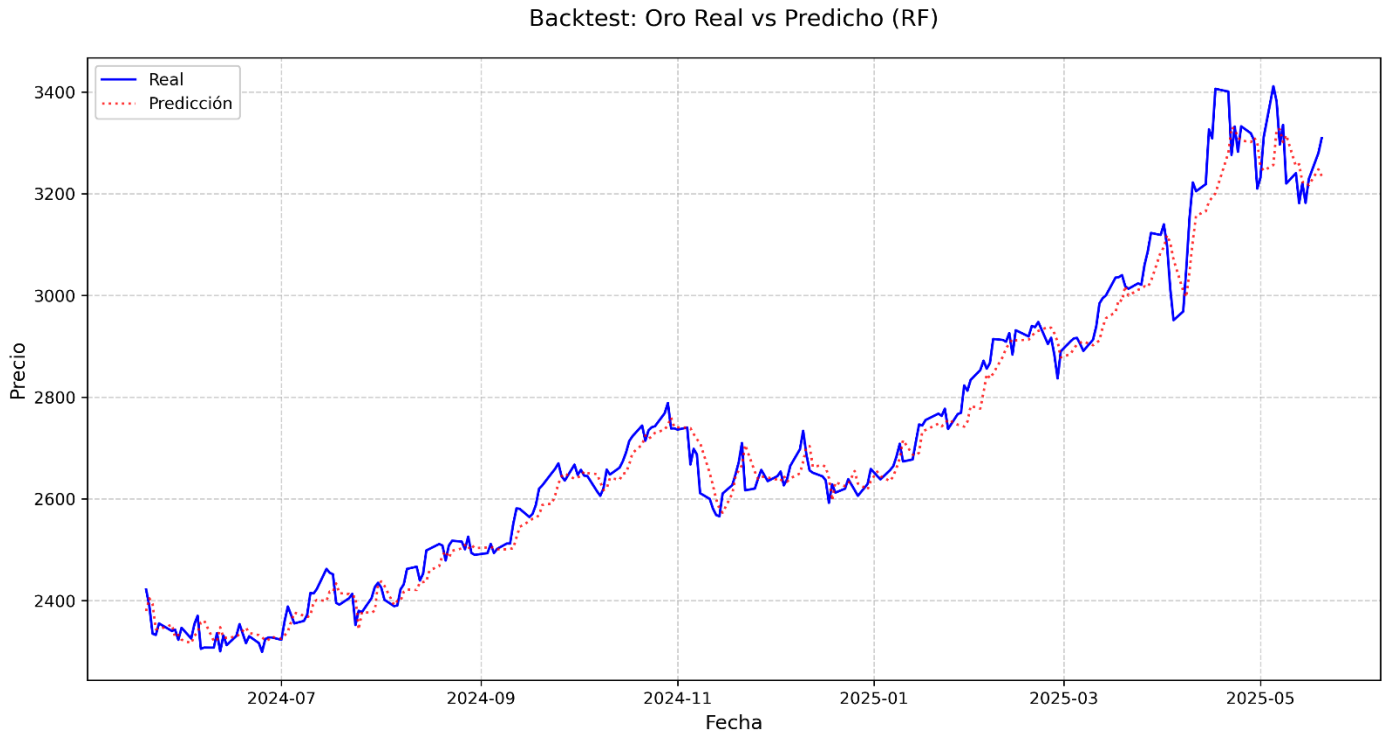

Imagen 1- Fuente Propia Colab Python

Modelo Gradient Boosting Regressor

El modelo Gradient Boosting (GBR) se implementó con un conjunto de variables técnicas que incluyen precios históricos (Close, High, Low, Open), volumen e indicadores clave como EMA, Bandas de Bollinger y ADX. Estas features se seleccionaron para capturar patrones de mercado y tendencias, mientras que los lags temporales (Lag_1 a Lag_20) permitieron incorporar datos pasados crudos. La inclusión de estos indicadores técnicos buscó aprovechar relaciones no lineales y patrones complejos en los datos financieros.

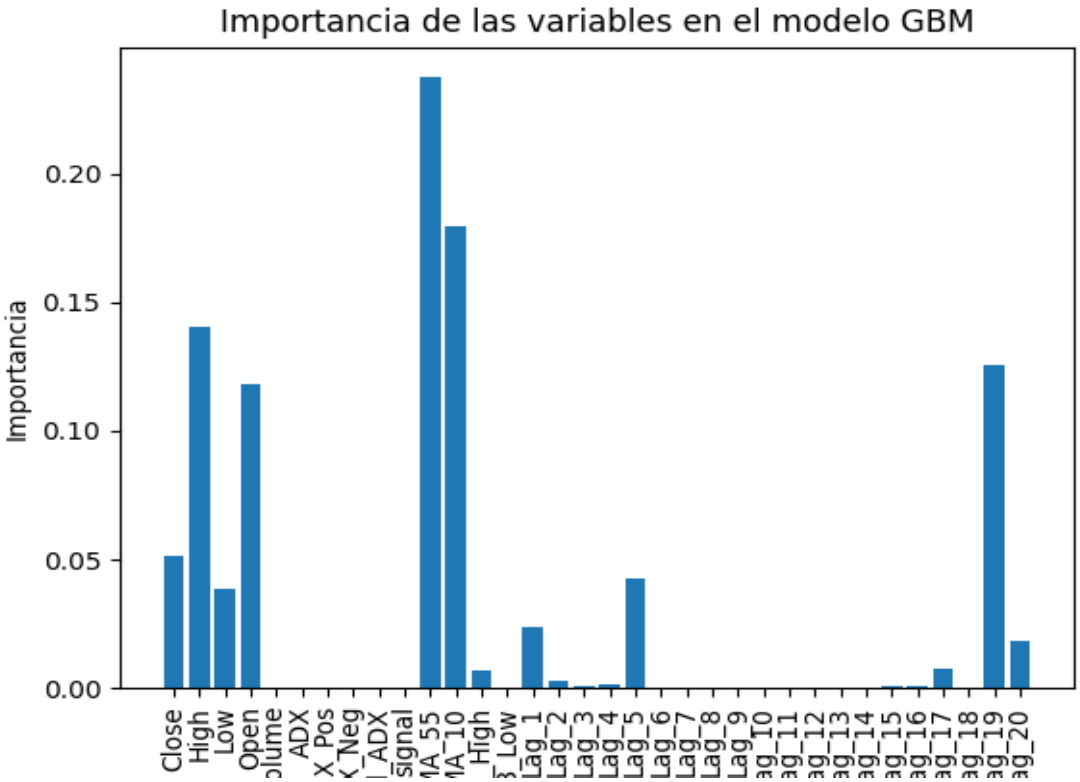

Imagen 2- Fuente Propia Colab Python

Como puede observase en la imagen 2 las variables que mas significativas en el modelo fueron las vinculadas al precio, como era de esperarse, sin embargo el precio suavizado (EMAS de 10 y 55) fue el de mayo impacto, también existe significancia con los lags de 5, 19 y 20, los cuales corresponderían en principio a los valores de la semana anterior al precio y del mes anterior, estas variables deberían analizarse en mayor profundidad en pruebas posteriores.

El modelo se entrenó con una ventana móvil de 1,008 datos (aproximadamente 4 años) y se evaluó en los últimos 252 días (1 año). Se utilizó GridSearchCV para optimizar hiperparámetros, obteniendo como mejor configuración: learning_rate=0.1, max_depth=3, min_samples_split=5 y n_estimators=50. Esta combinación logró un equilibrio entre capacidad predictiva y eficiencia computacional, evitando sobreajuste mediante profundidad limitada y un número moderado de estimadores.

El modelo alcanzó un R^2 de 0.9766, indicando un excelente ajuste a los datos, aunque este valor como en el modelo anterior podría estar influenciado por la autocorrelación natural de los precios. El MAE de 32.52 sugiere que, en promedio, las predicciones se desviaron en esta cantidad del precio real, lo que es relevante dependiendo del rango de precios del oro. En el backtesting, la estrategia generó una rentabilidad del 16.95% con un 64.10% de operaciones positivas, demostrando capacidad predictiva pero con margen de mejora en la consistencia de las señales. Si observamos la imagen 2 en comparación con la 1, estas predicciones resultan ser mas reactivas por lo que genera menso señales de entrada que el modelo anterior.

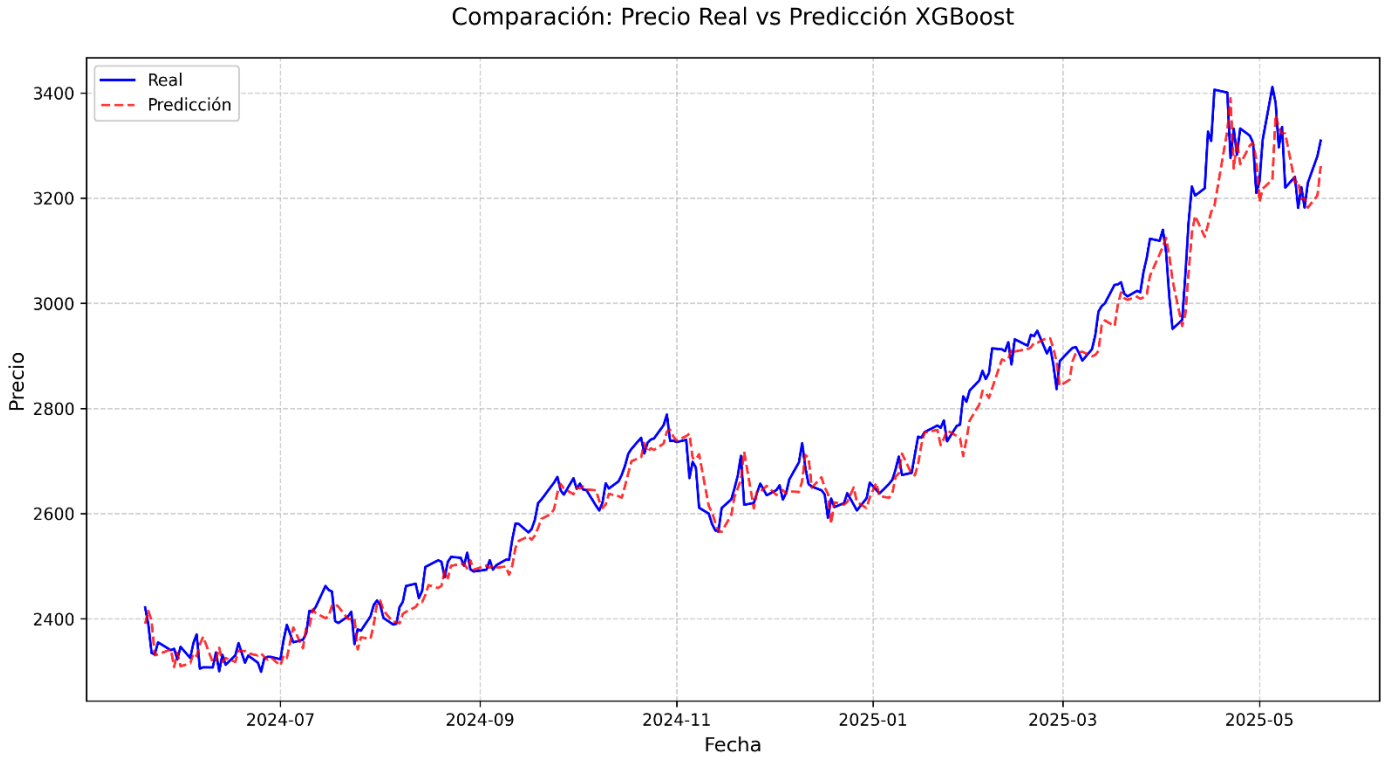

Imagen 3- Fuente Propia Colab Python

Descripción del Modelo LSTM para Predicción de Retornos del Oro

El modelo LSTM procesó tres variables clave escaladas: volatilidad diaria (ScaledVolatility), retornos (ScaledReturn) y volumen (ScaledVolume), utilizando ventanas temporales de 20 días. Estas entradas fueron preprocesadas mediante normalización exponencial (EWMA) con una semivida de 10 días, lo que permite capturar tendencias y volatilidad reciente. Los datos se dividieron en conjuntos de entrenamiento y prueba, manteniendo la estructura temporal para evitar look-ahead bias.

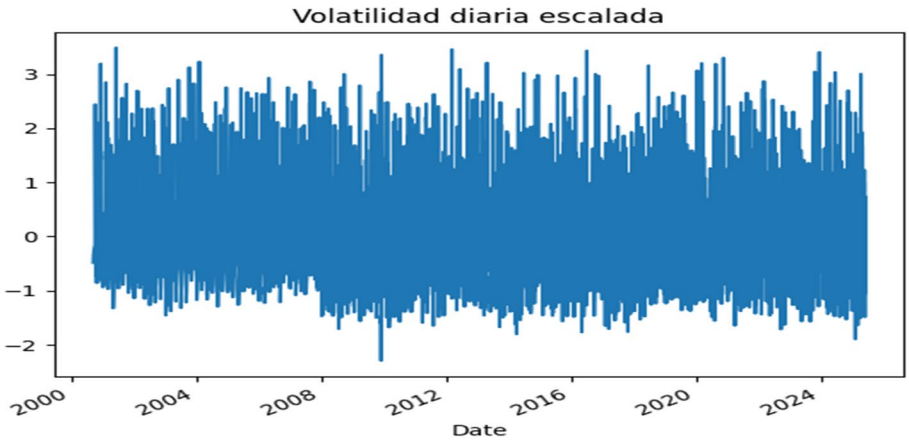

Imagen 4- Fuente Propia Colab Python

La arquitectura empleó dos capas LSTM con 32 unidades cada una, seguidas de una capa densa sin bias para predecir retornos escalados. Se entrenó durante 10 épocas con SGD y learning rate de 0.001, optimizando el error cuadrático medio (MSE). El backtesting se realizó con ventanas móviles, reentrenando el modelo incrementalmente para simular condiciones reales de trading.

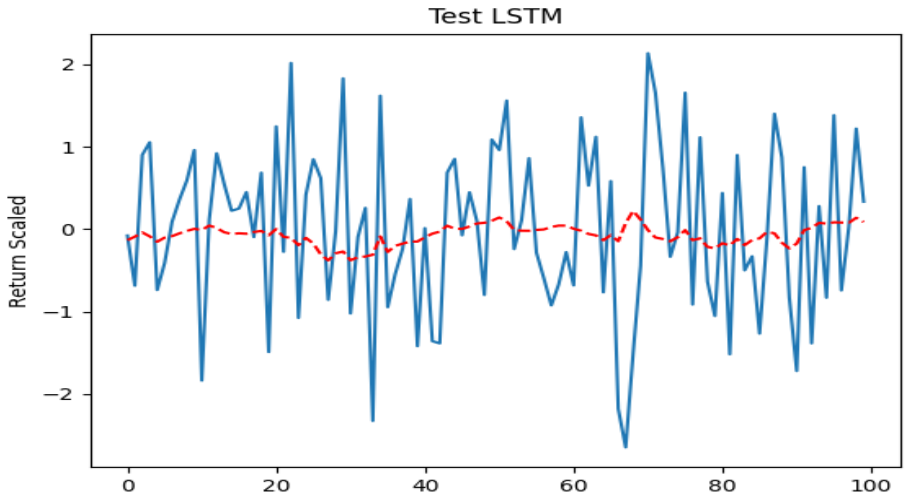

Imagen 5- Fuente Propia Colab Python

En la imagen 4 como bien indica la autora …" Los valores de retorno reales para una subsección del período de prueba (línea continua) se grafican frente a los pronósticos de la red neuronal (línea discontinua roja). La escala del pronóstico es tan diferente de los datos reales que dificulta la evaluación del modelo."…

Sin embargo, al aplicarse la correlación de Pearson con (0.1436) y p-value con (0.00017) indican una relación estadísticamente significativa pero débil entre predicciones y valores reales en la escala normalizada. Esto sugiere que el modelo captura parcialmente los patrones temporales, pero con margen de mejora en precisión. Este podría ser tomado como base para incorporar nuevos inputs que pudieran mejorar el modelo.

Conclusiones:

Los resultados obtenidos con los tres modelos (Random Forest, Gradient Boosting y LSTM) revelan ventajas y limitaciones clave para la predicción del precio del oro. El **Random Forest demostró ser la opción más sólida en el corto plazo**, con un MAE de 31.65 en valores des-escalados y una rentabilidad del 27.83% en backtesting reciente. Su simplicidad, velocidad de entrenamiento y estabilidad lo hacen ideal para implementaciones inmediatas, especialmente cuando se prioriza la operativa diaria. Sin embargo, su naturaleza estática limita su capacidad para adaptarse a cambios estructurales en tendencias de largo plazo.

Por otro lado, el **LSTM mostró un rendimiento consistente pero con margen de mejora** (MSE promedio de 0.8071 en retornos escalados). Si bien captura patrones temporales básicos, su error relativamente alto sugiere que necesita ajustes para ser competitivo. Incrementar la ventana temporal a 60-90 días e incorporar variables macroeconómicas (como inflación o tasas de interés) o también alguna variables categóricas como el sentimiento del mercado o conflictos internacionales podría potenciar su capacidad predictiva. A largo plazo, una LSTM mejorada

sería la opción preferida, especialmente para identificar tendencias complejas que los modelos basados en árboles no pueden extrapolar.

La validación cruzada tradicional no es adecuada para RF y GBR en este contexto, ya que ambos modelos requieren una secuencia temporal estricta (usar datos de *t-1* para predecir *t*). Para el LSTM, la VC temporal es viable, pero los resultados actuales indican que el modelo aún no aprovecha plenamente su potencial. En producción, RF puede usarse diariamente actualizando solo los datos más recientes, mientras que la LSTM requeriría un reentrenamiento periódico con ventanas móviles ampliadas.

En el corto plazo, **Random Forest es la mejor opción** por su equilibrio entre rendimiento y facilidad de implementación. Su bajo costo computacional y resultados estables lo hacen ideal para entornos operativos. Para horizontes más largos, se propone mejorar la LSTM mediante: 1) ventanas temporales extendidas, 2) inclusión de datos macro y 3) cambio a predicción direccional binaria. Esta evolución permitiría capturar patrones complejos y cambios estructurales, aunque requerirá mayor inversión en desarrollo y recursos. La transición entre modelos debería basarse en pruebas continuas de rendimiento, validando especialmente periodos de alta volatilidad.

Link: https://colab.research.google.com/drive/1WpRdxyb2JDYyYdOsG7NsD28eZ45hVxUZ?usp=sharing